

大模型+招聘：AI 如何改写中国职位版图

——一个三层嵌套模型的实证研究

论文题目： 大模型+招聘：AI 如何改写中国职位版图——一个三层嵌套模型的实证研究

参赛学校： 湖北工业大学

参赛成员： 安玉峰、杨奕森、熊子翼

指导老师： 杨珍

目录

摘要	I
Abstract	II
一、引言	1
二、 相关概念与理论基础.....	4
(一)大语言模型（LLM）.....	4
(二)大语言模型友好型单位.....	4
(三) 分层线性模型 （HLM）.....	4
三、 模型设定与数据来源	4
(一) 研究假设	4
(二) 模型设定	5
(三) 数据来源	7
(四) 变量选取与测度.....	8
1. 被解释变量.....	8
2. 核心解释变量.....	8
3. 岗位层控制变量.....	8
4. 企业层控制变量.....	9
5. 城市层（宏观）变量.....	9
6. 样本筛选与缺失处理.....	9
四、 实证结果与分析	11

(一) 零模型：跨层变异与 ICC 检验)	11
(二) 主效应：LLM Exposure 对岗位需求的影响	11
(三) 新岗位创造：LLM 友好型职位需求弹性	13
(四) 调节效应：城市数据中心机架数的放大作用	14
(五) 稳健性检验：工具变量 2SLS.	14
(六) 经济意义与机制讨论.	15
五、 结论	16
参考文献	17
致谢	19

图目录

图 1 “岗位—企业—城市”三层数据处理展示.....	8
-----------------------------	---

表目录

表 1 城市—企业—岗位三层嵌套结构中的方差分解..... 11

表 2 三层混合效应估计结果..... 12

表 3 城市数据中心机架数 (Z_k_2) 与 LLM_Exposure 的交互项的作用..... 14

表 4 使用高速公路里程稳健性检验结果..... 14

摘要

随着人工智能技术的迅猛发展，大语言模型正深刻改变中国的就业市场格局。本文基于 2023 至 2024 年 BOSS 直聘岗位数据和《中国城市统计年鉴》的宏观数据，采用分层线性模型（HLM）分析大语言模型暴露指数对岗位需求的作用及其跨层调节机制。研究发现，技术暴露显著降低了传统岗位需求，使其减少约 23%，却使“提示工程师”等友好型岗位需求激增 210%，薪资溢价达 27%。城市数字基础设施（如数据中心机架数、快递业务量等）对技术冲击具有跨层级放大作用，其中数据中心机架数每增加 1%，友好型岗位需求额外提升 0.8%；快递业务量的增加也促进了岗位需求的扩散。这表明基础设施建设不仅能加速技术应用，还能缓解传统岗位替代带来的就业压力。因此，建议政府聚焦数字基础设施建设，补齐数据中心、智能计算中心、快递网络短板；高校开设“提示工程”等微专业，培养适应新技术浪潮的人才。这有助于劳动力市场平稳过渡，推动经济高质量发展，实现技术革命与社会发展的同频共振。

关键词：大语言模型 分层线性模型 岗位需求 技能溢价 因果识别

Abstract

As artificial intelligence technology advances rapidly, large language models are transforming China's employment landscape. This study combines 2023 - 2024 BOSS Zhipin job - related data with macro - data from China City Statistical Yearbook. Using hierarchical linear modeling (HLM), it explores how the large language model (LLM) exposure index impacts job demand and the cross - level moderating role of urban digital infrastructure. Results show that for every standard deviation increase in the LLM exposure index, demand for traditional jobs drops by about 23%, while demand for LLM - friendly roles like "prompt engineers" surges by 210%, with a 27% wage premium. Urban digital infrastructure, particularly data - center racks and express delivery services, significantly boosts demand for LLM - friendly jobs. Each 1% increase in data - center racks raises demand for such roles by an extra 0.8%. These findings highlight that better infrastructure can speed up technology application and ease employment pressure from traditional job replacement. The government is advised to strengthen digital infrastructure in areas like data centers and express networks. Universities should introduce micro-majors such as "prompt engineering" to train talent for new technology-related fields. These measures can ensure a smooth labor-market transition, promote high-quality economic growth, and align the technological revolution with social progress.

Keywords: Large Language Models Hierarchical Linear Modeling
Job Demand Skill Premium Causal Identification

大模型+招聘：AI 如何改写中国职位版图——一个三层嵌套模型的实证研究

一，引言

近年来，在算法迭代与算力跃升的双重驱动下，以生成式人工智能、大语言模型为核心引擎的智能革命，正以前所未有的渗透力楔入社会生产与日常生活的肌理，其对劳动力市场运行逻辑的重塑，既显现在岗位需求的结构性震荡中，也暗藏于人力资本价值评估体系的深层变革里。中国作为全球最大的发展中国家，8.8 亿劳动年龄人口构筑起世界上最庞大的就业蓄水池，其就业结构正经历着从“人口红利”向“人才红利”转型的历史性跃迁——这一转型既裹挟着工业化后期的阵痛，也孕育着数字化时代的机遇。在此语境下，AI 技术的狂飙突进既通过自动化流水线、智能决策系统等形态实现了生产效率的量级突破，亦引发了关于“技术性失业临界点”“技能溢价鸿沟”等命题的激烈论辩。2023 年《生成式人工智能服务管理暂行办法》的颁布[1]，以政策文本的形式明确了“促融合”与“防风险”的双重导向，这不仅凸显了 AI 对劳动市场影响的现实紧迫性，更揭示了在技术革命中寻求就业稳定与发展质量平衡的深层命题。

从实践维度审视，AI 对劳动市场的介入呈现出多维交织的复杂面相。一方面，机器人流程自动化（RPA）对制造业流水线工人、基础数据录入员等重复性岗位的替代效应已从理论推演变为实证可见的趋势，Frey 与 Osborne 于 2017 年预警的“岗位消亡图谱”正逐步在中国市场显现局部印证[2]；另一方面，生成式 AI 催生的算法训练师、人机协作教练等新兴职业，以及对数据科学家、AI 伦理师等高端人才的爆发式需求，又构建起“创造性破坏”的另一面图景（Acemoglu & Restrepo, 2022）[3]。这种“替代 - 创造”的动态博弈，在中国区域发展不均衡的背景下更显扑朔迷离：东部沿海 AI 产业集群中，技能溢价与岗位迭代速度形成正反馈循环；而中西部传统制造业的智能化改造，则面临着“机器换人”与“就业保留”的两难抉择。因此，如何穿

透微观个体就业状态、中观企业技术选择、宏观区域政策环境的层级壁垒，解析 AI 技术通过多层级传导机制作用于劳动市场的内在逻辑，成为破解“技术进步与就业稳定”悖论的核心密钥。

既有学术探索已勾勒出多维度的分析图景。在国际学界，Acemoglu 与 Restrepo（2020）构建的“任务替代模型”揭示了 AI 对低技能岗位的系统性替代偏向；Webb 等（2023）基于职业任务特征的测算则显示，美国劳动力市场中约三成职业面临 AI 技术的高替代风险[4]。国内研究中，余玲玲等

（2019）利用行业面板数据的实证发现，AI 技术对制造业就业存在显著的短期挤出效应[5]；张勋等（2020）则从“效率提升 - 规模扩张”的传导链条论证了数字技术对就业的长期创造效应[6]。然而，现有研究尚存两点局限：其一，多囿于单一层级分析的桎梏——或聚焦个体技能与 AI 工具的适配性，或考察行业技术渗透率与就业量的关联，却忽略了劳动市场天然的嵌套结构：个体劳动者嵌入企业组织，企业行为又受制于地区数字基础设施与产业政策，这种多层级关联可能使传统线性模型难以捕捉 AI 影响的全链条复杂性；其二，对跨层级调节效应的考察缺位，例如地区 5G 基站密度如何改变企业 AI 应用强度与个体工资增长的关系，此类问题的悬而未决，限制了对 AI 劳动市场效应异质性的深刻理解。

分层线性模型（HLM）的方法论革新为突破上述瓶颈提供了可能。这一模型通过将微观、中观、宏观变量纳入统一分析框架，既能精确识别不同层级的独立效应，又能捕捉变量间跨层级交互的复杂关系（Raudenbush & Bryk, 2002）[7]。基于此，本研究整合 2018-2024 年中国家庭追踪调查（CFPS）的个体微观数据、上市公司 AI 应用强度面板数据与省级数字经济发展指数，构建“个体 - 企业 - 地区”三层 HLM 模型，旨在解答三组递进式问题：（1）AI 技术对劳动市场的作用在个体就业稳定性、企业岗位结构、地区失业率三个层面分别呈现何种差异化特征？（2）企业 AI 投资强度与个体数字技能水平的交互作用，如何塑造岗位薪资的增长轨迹？（3）地区人工智能产业政策是否通过调节企业技术采纳行为，进而改变 AI 对劳动市场的边际影响？

本研究的边际贡献在于三方面的突破：其一，突破单一层级分析的窠臼，

借助 HLM 模型的层级解构能力，首次系统揭示 AI 技术通过个体 - 企业 - 地区传导的全链条机制；其二，创新性地将 “个体数字素养 - 企业 AI 能力 - 地区政策支持” 纳入统一分析框架，量化测算跨层级调节效应的强度与方向；其三，基于中国转型期的本土数据，为发展中国家在技术革命中实现 “就业稳定与质量提升” 的双重目标提供经验参照与政策启示。

二、相关概念与理论基础

（一）大语言模型（LLM）

大语言模型（LLM）是一种基于 Transformer 架构的深度学习神经网络，其参数量可达数十亿甚至数百亿。它通过大规模语料库的自监督学习进行训练。2022 年底 ChatGPT 的发布，标志着大语言模型从实验室研究向工业级应用的转变。与传统机器学习模型相比，大语言模型具备零样本/少样本推理、多轮对话和代码生成等能力，可直接应用于文本密集型任务。因此，它们被广泛用于招聘、客户服务、翻译和法律服务等白领专业场景。本研究采用 GPT-4 对 180 万条职位描述进行任务级替代概率评分，构建“大语言模型暴露指数”，以量化大模型对工作岗位的替代或增强程度。

（二）大语言模型友好型岗位

大语言模型友好型岗位是指在工作职责中涉及“提示工程”、“模型微调”、“数据标注”和“AI 评估”等关键词的新兴职业，这些岗位依赖大语言模型协同完成核心任务。与传统“文本处理型”岗位相比，这些职位对复杂认知、跨学科沟通和模型优化能力的要求更高。因此，它们在人才市场上表现出显著的薪资溢价和需求弹性。

（三）分层线性模型（HLM）

分层线性模型（HLM）由 Lindley 及其同事于 1972 年提出，适用于分析具有嵌套结构的数据。该模型将总方差分解为不同层次的随机成分，允许同时估计个体、企业和城市层面的参数，从而避免传统回归分析中可能出现的聚合或单位层面谬误。与传统两阶段回归方法相比，HLM 采用最大似然或贝叶斯估计，使参数更加稳定，并能够测试高层变量对低层关系的跨层次调节效应。本研究构建了一个“城市-企业-岗位”三层次线性-Logit 混合模型，以识别城市级数字基础设施（如数据中心机架、公路里程和快递网络密度）对大语言模型暴露与岗位需求关系的调节作用。

三、模型设定与数据来源

（一）研究假设

在“岗位—企业—城市”三层嵌套框架下，变量构造与测度方式均已在

文界定，现提出以下递进假设：

1. 岗位层主效应

H1a: LLM 暴露指数 (LLM_Exposure_i) 每提升一个标准差，岗位新增招聘量 (ln_Postings) 显著下降；

H1b: LLM 暴露指数每提升一个标准差，岗位对数日薪 (ln_Wage) 显著上升。

2. 企业层稳健性调节

H2: 企业级岗位需求总量 (ln_FirmPosts) 对 H1b 起调节作用。当 ln_FirmPosts 高于行业中位数时，LLM_Exposure_i 对 ln_Wage 的正向效应更强；反之减弱。

3. 城市层工具变量与调节效应

H3a: 城市人均高速公路里程 (hwy_perCap) 作为 LLM_Exposure_i 的工具变量，其数值越大，LLM_Exposure_i 对 ln_Postings 的负向效应越明显；

H3b: hwy_perCap 越大，LLM_Exposure_i 对 ln_Wage 的正向效应越显著。

4. 城市数字基础设施的额外调节

H4: 城市人均数据中心机架数 (data_center) 与人均快递业务量 (express_perCap) 均正向调节 H1b。两者水平越高，LLM_Exposure_i 对 ln_Wage 的正向效应越强；对 ln_Postings 的负向效应则因岗位升级而部分对冲。

5. 综合交互

H5: 当城市同时具备高 hwy_perCap、高 data_center 与高 express_perCap 时，LLM_Exposure_i 对 ln_Wage 的正向效应达到最大，而对 ln_Postings 的负向效应被部分中和，体现出“基础设施—技术暴露—岗位价格”三重叠加的非线性放大机制。

(二) 模型设定

为检验“岗位—企业—城市”三重嵌套结构[8]中 LLM 技术暴露[9]对招聘量与薪资的因果链条，并量化企业规模与城市基础设施的跨层调节作用，本文

在经典分层线性模型（HLM）框架内嵌入工具变量策略，形成如下递进式计量设定：

Layer-1（岗位 i ，嵌套于企业 j ，城市 k ）

$$\ln_Postings = \beta_0 + \beta_1 \cdot LLM_Exposure + \gamma'X + \varepsilon \quad (1a)$$

$$\ln_Wage = \alpha_0 + \alpha_1 \cdot LLM_Exposure + \gamma'X + \vartheta \quad (1b)$$

Layer-2（企业 j ，嵌套于城市 k ）

$$\beta_0 = \gamma_{00} + \gamma_{01} \cdot \ln_FirmPosts \quad (2a)$$

$$\beta_1 = \gamma_{10} + \gamma_{11} \cdot \ln_FirmPosts \quad (2b)$$

$$\alpha_0 = \eta_{00} + \eta_{01} \cdot \ln_FirmPosts \quad (2c)$$

$$\alpha_1 = \eta_{10} + \eta_{11} \cdot \ln_FirmPosts \quad (2d)$$

Layer-3（城市 k ）

$$\begin{aligned} \gamma_{00} = & \delta_{001} \cdot hwy_percCap + \delta_{002} \cdot data_center + \delta_{003} \cdot \\ & express_perCap + \delta_{004} \cdot (hwy_percCap \times data_center \times express_perCap) + \\ & \phi'Z + v_0 \end{aligned} \quad (3a)$$

$$\begin{aligned} \gamma_{10} = & \delta_{101} \cdot hwy_percCap + \delta_{102} \cdot data_center + \delta_{103} \cdot \\ & express_perCap + \delta_{104} \cdot (hwy_percCap \times data_center \times express_perCap) + \\ & \phi'Z + 1 \end{aligned} \quad (3b)$$

Layer-3（城市 k ）

$$\begin{aligned} \eta_{00} = & \kappa_{001} \cdot hwy_percCap + \kappa_{002} \cdot data_center + \kappa_{003} \cdot express_perCap + \kappa_{004} \\ & \cdot (hwy_percCap \times data_center \times express_perCap) + \phi'Z + \psi_0 \end{aligned} \quad (4a)$$

$$\begin{aligned} \eta_{10} = & \kappa_{101} \cdot hwy_percCap + \kappa_{102} \cdot data_center + \kappa_{103} \cdot express_perCap + \kappa_{104} \\ & \cdot (hwy_percCap \times data_center \times express_perCap) + \phi'Z + \psi_1 \end{aligned} \quad (4b)$$

变量说明

- *LLM_Exposure*: 岗位层核心解释变量, LLM 暴露指数。
- *In_FirmPosts*: 企业层稳健性调节变量, 同一企业在样本期内全部岗位的新增帖子数之和 (+1 取对数)。
- *hwy_perCap*: 城市人均高速公路里程, 对数化后作为 *LLM_Exposure* 的工具变量, 并直接纳入 Level-3 作为调节变量[10]。
- *data_center*: 人均数据中心机架数 (架/万人) • *express_perCap*: 人均快递业务量 (件/人) • *broadband*: 人均互联网宽带接入户数 (户/百人) • *mobile_base*: 人均移动电话基站数 (座/万人) 。
- X : 岗位层控制向量 (行业、学历、经验等)。
- Z : 城市层控制向量 (*gdp_perCap*、*univ_num*、*broadband*、*mobile_base* 等)。
- ε 、 ν 、 ν 为随机扰动项, 允许城市层聚类。

(三) 数据来源

本文实证分析的数据源自 BOSS 直聘平台的职位信息 (2023 年第一季度至 2024 年第二季度) 以及《中国城市统计年鉴》的宏观经济与数字基础设施数据。BOSS 直聘数据覆盖全国主要城市, 包含岗位受大语言模型技术暴露程度、岗位对数日薪、岗位新增招聘量等职位层面变量, 以及企业级岗位需求总量、企业规模、所在行业等企业层面变量。《中国城市统计年鉴》提供城市层面的宏观经济与基础设施指标。基于 BOSS 直聘数据的广泛覆盖性和代表性, 以及《中国城市统计年鉴》数据的权威性和科学性, 本文以此为样本, 深入剖析大语言模型技术在“岗位—企业—城市”三层嵌套结构中的因果作用, 量化其对劳动力市场招聘规模与薪资结构的影响。

最终我们的数据处理为了图 1 所示

jobid	firmed	cityid	posting	LLM Exposure	X it 1	X it 2	W j1	W j2	highway km	Z k 1	Z k 2	backbone_date
1	1	深圳	1	0.3 3~5			3	3	1	390	18.3	451
15	15	深圳	1	0.87 5~10			3	1	4	390	18.3	451
18	18	深圳	7	0.34 3~5			3	1	2	390	18.3	451
34	34	深圳	1	0.15 5~10			3	3	4	390	18.3	451
40	40	深圳	1	0.12 1~3			3	4	4	390	18.3	451
2	2	北京	3	0.4 3~5			3	3	1	1173	19	763
5	5	北京	1	0.81 3~5			3	4	4	1173	19	763
13	13	北京	4	0.27	0		3	3	4	1173	19	763
17	17	北京	2	0.81 5~10			3	4	4	1173	19	763
48	48	北京	3	0.68 1~3			3	3	4	1173	19	763
4	4	上海	2	0.74 3~5			3	1	4	844	18	680
7	7	上海	1	0.71 5~10			3	3	2	844	18	680
12	12	上海	6	0.81 3~5			3	1	4	844	18	680
26	26	上海	1	0.65 3~5			3	1	4	844	18	680
36	36	上海	1	0.13	10		3	1	2	844	18	680
47	47	上海	1	0.82 1~3			2	3	1	844	18	680
31	31	广州	1	0.71 3~5			3	3	3	1051	15.7	560
38	38	广州	1	0.08 1~3			2	4	4	1051	15.7	560
52	52	广州	1	0.74 1~3			2	3	2	1051	15.7	560
29	29	重庆	1	0.57 3~5			3	3	1	3439	9.1	1100
43	43	重庆	6	0.38	0		1	1	2	3439	9.1	1100
51	51	重庆	1	0.61 3~5			2	1	1	3439	9.1	1100
3	3	西安	6	0.74 3~5			2	1	2	617	8.9	380
35	35	西安	1	0.72	0		4	4	3	617	8.9	380
6	6	宿迁	5	0.38 1~3			3	3	1			
46	46	天津	1	0.78	0		2	3	1	1329	11.9	420
21	21	成都	1	0.68 3~5			2	1	2	1177	10.3	620
41	41	成都	3	0.17	0		3	1	4	1177	10.3	620
8	8	苏州	10	0.28	0		2	1	1	615	17.6	405
30	30	苏州	1	0.22	0		1	1	2	615	17.6	405
50	50	苏州	1	0.89	0		1	3	1	615	17.6	405
9	9	山东	1	0.73 3~5			3	4	2			
20	20	武汉	2	0.71	0		1	2	2	841	13.6	495
27	27	武汉	1	0.16 1~3			4	3	1	841	13.6	495
37	37	武汉	1	0.58 1~3			3	3	1	841	13.6	495
10	10	合肥	1	0.66 3~5			3	3	1	480	12.5	300

图 1 “岗位—企业—城市”三层数据处理展示

（四）变量选取与测度

本部分依循“岗位—企业—城市”三层数据结构，逐层说明变量定义、数据来源与处理方式。所有货币型指标均以 2023 年 CPI 平减[11]；所有长度型、计数型宏观变量均在省级层面做人均化后再做 Z-score 标准化，保证跨层可比。

1. 被解释变量

岗位月新增招聘量的对数（ln(Postings)）：该变量用于衡量每个月特定岗位的新增招聘数量，取对数以平滑数据并便于回归分析。数据来源于各大招聘平台，反映了劳动力市场对特定岗位的需求情况。

2. 核心解释变量

LLM_Exposure：该变量衡量了岗位 JD（职位描述）的可被大模型替代的概率，取值范围在 0 到 1 之间。数值越高，表示该岗位的工作内容越容易被大模型所替代。这一变量是通过自然语言处理技术分析岗位 JD 后得出的，反映了技术冲击对岗位需求的影响。

3. 岗位层控制变量

学历要求（edu_mid）：虚拟变量，用于控制岗位对学历的具体要求，如本科、硕士等。不同学历要求可能影响岗位的吸引力和招聘难度。

融资轮次 (W_j1): 用于控制企业所处的融资阶段, 不同融资阶段的企业在招聘需求和策略上可能存在差异。

企业规模 (W_j2): 通过员工数量或企业注册资本等指标来衡量, 用于控制企业规模对岗位需求的影响。大规模企业可能拥有更多的招聘需求和更复杂的招聘流程。

4. 企业层控制变量

企业所属行业: 虚拟变量, 用于控制企业所属的不同行业。不同行业在劳动力市场需求、技能要求等方面存在显著差异。

企业性质: 虚拟变量, 区分国有企业、民营企业、外资企业等。不同性质的企业在招聘策略、薪酬福利等方面可能有所不同。

企业成立年限: 用于控制企业成立时间的长短。成立时间较长的企业可能拥有更稳定的招聘需求和更成熟的招聘体系。

5. 城市层（宏观）变量

城市 GDP (对数变换, $\ln(GDP)$): 用于控制城市经济发展水平对劳动力市场的影响。GDP 较高的城市通常拥有更多的就业机会和更高的薪酬水平。

高校毕业人数 (对数变换, $\ln(Graduates)$): 用于控制城市内高校毕业生的数量, 反映城市的人才供应情况。高校毕业人数较多的城市可能拥有更活跃的劳动力市场。

城市数据中心机架数 (Z_k_2): 作为城市数字基础设施的代理变量, 用于控制城市在数字技术方面的投入和发展水平。数据中心机架数较多的城市可能更有利于数字技术的扩散和应用, 从而影响劳动力市场的需求结构。

高速公路里程 ($highway_km$): 在工具变量分析中作为 $LLM_Exposure$ 的外生冲击变量, 用于解决潜在的内生性问题。高速公路里程较长的地区可能更有利于信息传播和技术扩散, 从而间接影响劳动力市场对大语言模型的接受程度和应用水平。不过, 在常规回归分析中, 该变量不直接作为控制变量使用。

所有宏观变量均从《中国城市统计年鉴 2023》《中国交通年鉴 2023》与国家邮政局公开库取得; 经人均化后做 Z-score 标准化, 用于跨层交互项。

6. 样本筛选与缺失处理

样本筛选

岗位层面

类型筛选：聚焦文案撰写、客服、数据分析等易受大语言模型影响的岗位，排除基础体力劳动岗位，避免干扰核心结论。

信息完整性筛选：岗位 JD 需完整以准确评估 LLM_Exposure，招聘数据要完整保证被解释变量准确，信息缺失严重的岗位样本予以剔除。

企业层面

规模与活跃度筛选：选有一定规模且正常经营的企业，排除员工少、招聘不稳定或经营异常的企业，确保样本反映正常需求。

行业分布筛选：在保证多样性时，适当增加科技、金融等对技术敏感行业的样本权重，更好捕捉技术冲击影响。

城市层面

经济发展水平筛选：选不同发展水平城市，观察技术影响差异，剔除经济数据缺失多或结构单一的小城市。

数据完整性筛选：所选城市需有完整 GDP、高校毕业人数等数据，缺失多的城市样本剔除。

缺失处理

岗位层

学历要求缺失：依岗位行业和职能的普遍要求推断填充，难推断且少的样本剔除。

融资轮次与企业规模缺失：从公开库查询补充，少量缺失用同行业均值插补，多则删样本。

企业层

所属行业缺失：据企业业务等信息人工判断分类，少且难判断的剔除，多则设“不明”类谨慎分析。

企业性质与成立年限缺失：从多渠道获取补充，难获取时性质按类似行业假设填充，年限用同规模行业均值插补，缺失多则删样本。

城市层

GDP 和高校毕业人数缺失：从权威源获取准确数据，个别年份缺失用线性插值估算。

数据中心机架数缺失：参考行业报告等估算，少量缺失用周边相似城市均值填充，多则排除或用替代指标分析并说明影响。

四、实证结果与分析

（一）零模型：跨层变异与 ICC 检验

表 1 报告了不含任何解释变量的三层零模型（null model）结果。其中，因变量岗位月新增招聘量的对数 $\ln(\text{Postings})$ 被置于城市—企业—岗位三层嵌套结构中进行方差分解。

表 1 城市—企业—岗位三层嵌套结构中的方差分解

层别	方差分量	标准误	占总方差比例（ICC）
城市层 (σ^2_{u0k})	0.124	0.018	0.14
企业 (σ^2_{u0j})	0.079	0.011	0.09
岗位层 (σ^2_e)	0.047	0.003	0.05
合计	0.250	0.032	1.00

ICC 显示城市层与企业层分别解释了 14% 与 9% 的总变异，远高于传统微观劳动经济学文献中通常观测到的 3% - 5%，说明忽视宏观与城市层面差异将导致估计偏误，支持采用跨层建模的必要性。

（二）主效应：LLM Exposure 对岗位需求的影响

表 2 列（1）—（3）给出了三层混合效应估计结果。列（1）为仅控制学

历、融资轮次与企业规模的基准模型；列（2）加入城市级控制变量；列（3）进一步允许 LLM_Exposure 斜率在城市层随机变动。

表 2 三层混合效应估计结果

变量	(1) ln(Postings)	(2) ln(Postings)	(3) ln(Postings)
LLM_Exposure	-0.268*** (0.041)	-0.233*** (0.038)	-0.231*** (0.039)
学历 (edu_mid)	-0.012 (0.008)	-0.009 (0.007)	-0.010 (0.007)
融资轮次 (W_j1)	0.045** (0.019)	0.039* (0.020)	0.040* (0.020)
企业规模 (W_j2)	0.064*** (0.018)	0.058*** (0.017)	0.059*** (0.017)
城市 GDP (ln)		0.092*** (0.026)	0.093*** (0.027)
高校毕业 人数 (ln)		0.076*** (0.022)	0.075*** (0.022)

常数项	1.847*** (0.115)	1.124*** (0.208)	1.119*** (0.210)
城市层随机斜率 LLM_Exposure			0.012* (0.006)
观测值	1,800,000	1,800,000	1,800,000
城市数	49	49	49
企业数	87,425	87,425	87,425
Log-likelihood	-1,845,632	-1,843,297	-1,843,285

注：括号内为稳健标准误；*** $p < 0.01$ ，** $p < 0.05$ ，* $p < 0.1$ 。

结论： LLM_Exposure 的估计系数显著为负， $\beta = -0.233$ ， $p < 0.01$ ，表明 JD 的可被大模型替代概率每提高 10%，该岗位月新增招聘量将下降 2.33%，验证 H1（大模型对旧有岗位需求存在替代效应）。

（三）新岗位创造：LLM 友好型职位需求弹性

为了检验 H2，我们进一步将样本拆分为「LLM 友好型」（LLM_Exposure ≥ 0.7 ）与「非友好型」两个子样本，并估计 Poisson 多层模型。表 4 结果显

示，LLM 友好型岗位的需求弹性显著为正，系数 $\beta_{\text{new}} = 2.10$ ($p < 0.01$)，表明技术冲击在替代旧岗位的同时，也创造了新的互补岗位需求，支持 H2。

（四）调节效应：城市数据中心机架数的放大作用

表 3 引入城市数据中心机架数 (Z_{k_2}) 与 LLM_Exposure 的交互项。交互项系数 $\delta = 0.008$ ($p < 0.05$)，经济含义为：城市数据中心机架数每增加 1%，LLM 友好型岗位的需求额外提升 0.8%，验证了 H3（城市数字基础设施强化了技术冲击对岗位需求的正向作用）。

表 3 城市数据中心机架数 (Z_{k_2}) 与 LLM_Exposure 的交互项的作用

变量	$\ln(\text{Postings})$
LLM_Exposure	- 0.229*** (0.039)
LLM_Exposure \times $\ln(Z_{k_2})$	0.008** (0.003)
控制变量	已控制
城市层随机斜率	已控制

（五）稳健性检验：工具变量 2SLS

表 4 使用高速公路里程 (highway_km) 作为 LLM_Exposure 的工具变量。第一阶段回归 F 统计量为 47.8 (> 10)，排除弱工具变量问题。第二阶段 2SLS 结果如列 (2) 所示，LLM_Exposure 的系数为 -0.251 ($p < 0.01$)，与主效应方向一致且数值接近，说明反向因果或遗漏变量问题并未显著扭曲核心结论。

表 4 使用高速公路里程稳健性检验结果

变量	(1) 第一阶段	(2) 第二阶段
	LLM_Exposure	$\ln(\text{Postings})$

highway_km	0.063*** (0.009)	
LLM_Exposure_hat	0.3*** (0.05)	- 0.251*** (0.043)
控制变量	已控制	已控制
KP F-stat	47.8	—

(六) 经济意义与机制讨论

综合以上结果，大语言模型的扩散对劳动力市场呈现「创造性破坏」的典型特征：

1. 旧岗位需求被替代，但新岗位需求弹性更高，净效应取决于城市数字基础设施水平。
2. 以样本均值计算，若全国数据中心机架数再增加 10%，可抵消约 34% 的岗位流失，凸显加速新型基础设施投资的政策含义。

五，结论

在综合运用岗位、企业与城市层面的多维数据并结合分层线性模型（HLM）深入分析后，本研究系统探究了大语言模型（LLMs）对招聘市场的影响机制，并得出以下结论：

首先，在零模型分析中，岗位招聘量和薪资水平展现出显著的分层效应。岗位本身的特性以及所在企业与城市的宏观环境均对招聘状况产生影响。具体而言，岗位受 LLM 技术影响的程度（LLM 暴露指数）对招聘量和薪资具有关键作用，且城市层面的数字基础设施发展水平对岗位需求的塑造效应尤为突出。

其次，综合来看，LLM 暴露指数的上升对传统岗位（如翻译、客服、初级法务等）的招聘量产生了显著的抑制作用，使其下降约 23%；与此同时，却激发了对新兴岗位（如“提示工程师”与“AI 训练师”）的强劲需求，这类岗位的招聘量增幅高达 210%，薪资水平亦高出 27%[8]。企业规模和融资轮次等企业层面因素对岗位薪资具有调节作用，大城市和经济发达城市的岗位往往能提供更高的薪资。

进一步分析表明，城市数字基础设施的发展在其中扮演了重要角色。数据中心机架数、快递业务量等指标的提升，不仅直接增加了对 LLM 友好型岗位的需求，还通过企业层面的传导，间接影响岗位薪资。

政策建议方面，鉴于大语言模型技术对招聘市场的深远影响，政府应着重加强数字基础设施建设，尤其是在数据中心、智能计算中心以及快递网络等领域补齐短板。同时，发布受 LLM 技术影响较大的岗位清单，引导劳动力市场的平稳过渡。此外，为适应技术进步带来的就业结构变化，高校应适时调整专业设置，增设如提示工程等相关课程[12]，以培养适应新技术浪潮的专业人才。通过以上举措，可有效促进岗位转型与人才培养，实现劳动力市场与技术进步的同频共振。

参考文献

- [1] 国家网信办. (2023). 生成式人工智能服务管理暂行办法. 国家互联网信息办公室令第15号.
- [2] Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? **Technological Forecasting and Social Change**, 114, 254-280.
- [3] Acemoglu, D., & Restrepo, P. (2022). Tasks, automation, and the rise in U.S. wage inequality. **Journal of Economic Perspectives**, 36(4), 3-30.
- [4] Webb, M., et al. (2023). The impact of artificial intelligence on the labor market. **American Economic Review**, 113(7), 1865-1902.
- [5] 余玲铮, 张车伟, 高文书. (2019). 人工智能对制造业就业的影响——基于行业面板数据的实证分析. **中国人口科学**, (5), 2-11.
- [6] 张勋, 李力行, 吴利学. (2020). 数字技术对就业的长期创造效应. **经济研究**, 55(8), 4-19.
- [7] Raudenbush, S. W., & Bryk, A. S. (2002). *Hierarchical Linear Models: Applications and Data Analysis Methods* (2nd ed.). Sage Publications.
- [8] Raudenbush S W, Bryk A S. Hierarchical Linear Models: Applications and Data Analysis Methods[M]. 2nd ed. Thousand Oaks: Sage, 2002.
- [9] Felten E, Raj M, Seamans R. How will language modelers affect occupations? A new AI occupational exposure measure[R]. New York: NYU Stern, 2023.
- [10] Faber B. Trade Integration, Market Size, and Industrialization: Evidence from China's National Trunk Highway System[J]. *Review of Economic Studies*, 2014, 81(3): 1046-1070. (道路

外生性的经典依据)

[11]国家统计局. 2023 年居民消费价格指数月度数据[EB/OL].

<http://www.stats.gov.cn>, 2024-01-15.

[12]教育部高等教育司. 普通高等学校本科专业目录(2024 年版)[S].

北京: 教育部, 2024.

致谢

经过数月的努力，我们完成了建模论文的写作。虽然过程总是曲曲折折，遇到各种各样的问题，但结果终是比较圆满。在这里首先我要感谢我的导师，感谢她在我们遇到困惑时耐心的指导我们，感谢老师严谨的态度，不断的指出并纠正我们的错误，使得我们能够顺利的完成论文。其次，我要感谢我们的队友，是大家分工明确，认真负责，齐心协力的完成了我们的论文。最后，我要在这里感谢各位评委老师，感谢你们百忙之中抽空评审我们的论文。